

# **DIAGNOSIS INDEKS KESEHATAN TRANSFORMATOR DAYA MENGGUNAKAN *LONG SHORT TERM MEMORY* (LSTM)**

## **LAPORAN TUGAS AKHIR**

**Oleh:**

**Muhammad Ali Wafa**

**102117002**



**FAKULTAS TEKNOLOGI INDUSTRI  
PROGRAM STUDI TEKNIK ELEKTRO  
UNIVERSITAS PERTAMINA  
2021**

# **DIAGNOSIS INDEKS KESEHATAN TRANSFORMATOR DAYA MENGGUNAKAN *LONG SHORT TERM MEMORY* (LSTM)**

## **LAPORAN TUGAS AKHIR**

**Oleh:**

**Muhammad Ali Wafa**

**102117002**



**FAKULTAS TEKNOLOGI INDUSTRI  
PROGRAM STUDI TEKNIK ELEKTRO  
UNIVERSITAS PERTAMINA  
2021**



## DAFTAR ISI

<b>DAFTAR ISI</b>	<b>iv</b>
<b>DAFTAR TABEL</b>	<b>vi</b>
<b>DAFTAR GAMBAR</b>	<b>vii</b>
<b>BAB I PENDAHULUAN</b>	<b>2</b>
1.1 Latar Belakang . . . . .	2
1.2 Rumusan Masalah . . . . .	3
1.3 Batasan Masalah . . . . .	3
1.4 Tujuan Perancangan . . . . .	3
1.5 Manfaat Perancangan . . . . .	4
1.6 Waktu Pelaksanaan Perancangan . . . . .	4
<b>BAB II TINJAUAN PUSTAKA</b>	<b>6</b>
2.1 Transformator Daya . . . . .	6
2.2 Indeks Kesehatan Trafo . . . . .	6
2.2.1 <i>Dissolve Gas Analysis</i> (DGA) . . . . .	6
2.2.2 Kualitas Minyak Transformator . . . . .	7
2.2.3 Pengujian Furan . . . . .	8
2.3 <i>Machine Learning</i> . . . . .	8
2.4 <i>Long Short Term Memory</i> (LSTM) . . . . .	9
2.4.1 <i>Forget Gate</i> . . . . .	9
2.4.2 <i>Input Gate</i> . . . . .	9
2.4.3 <i>Cell gate</i> . . . . .	10
2.4.4 <i>Output Gate</i> . . . . .	10
<b>BAB III KONSEP PERANCANGAN</b>	<b>12</b>
3.1 Diagram Alir Perancangan . . . . .	12
3.2 Pertimbangan Perancangan . . . . .	12

3.2.1	Akurasi . . . . .	13
3.2.2	Presisi . . . . .	13
3.2.3	Sensitifitas ( <i>recall</i> ) . . . . .	13
3.2.4	Spesificitiy . . . . .	13
3.2.5	<i>F1 Score</i> . . . . .	14
3.2.6	Waktu Pelatihan dan Pengujian . . . . .	14
3.3	Perancangan Model LSTM . . . . .	14
3.3.1	Jumlah <i>Neuron</i> . . . . .	14
3.3.2	Multilayer layer LSTM . . . . .	14
3.3.3	Rasio Dataset . . . . .	15
3.4	Analisis Teknis . . . . .	15
3.5	Peralatan dan Bahan . . . . .	16
<b>DAFTAR PUSTAKA</b>		<b>18</b>

## DAFTAR TABEL

Tabel 1.1	Waktu Pelaksanaan Tugas Akhir . . . . .	4
Tabel 2.1	Standar Pengujian Minyak Tranformator . . . . .	8
Tabel 2.2	Standar Pengujian Furan . . . . .	8
Tabel 3.1	<i>Confussion Matrrix</i> . . . . .	13
Tabel 3.2	Alat dan Bahan . . . . .	16

## DAFTAR GAMBAR

Gambar 2.1	Segitiga Duval [2] . . . . .	7
Gambar 3.1	Diagram Alir Perancangan Sistem Model LSTM . . . . .	12



Universitas  
**Pertamina**



# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Transformator daya merupakan salah satu peralatan dalam sistem kelistrikan yang memiliki peran fundamental. Dalam pengoperasiannya transformator berperan dalam menaikkan serta menurunkan tegangan pada jaringan transmisi. Apabila transformator daya tidak dapat bekerja dengan baik maka dapat menurunkan kualitas listrik atau lebih lanjut dapat menyebabkan terhentinya pelayanan listrik yang diterima oleh konsumen. Kerugian lainnya dapat membuat rugi-rugi daya menjadi semakin besar, hal ini tentunya dapat merugikan penyedia listrik. Menurut manufaktur usia transformator daya diperkirakan antara 25-40 tahun, tetapi terkadang terdapat transformator yang usianya di bawah range usia minimal telah rusak [1].

Pemeliharaan transformator daya sangat penting dilakukan untuk memastikan agar selalu dapat beroperasi dengan baik. Namun jika pemeliharaan dilakukan dengan intensitas yang tinggi tentunya dapat membuat dana yang harus dialokasikan semakin besar. Sedangkan diketahui bahwa transformator merupakan komponen yang membutuhkan hampir 60% dari biaya total pada gardu induk [1]. Sehingga diperlukan penjadwalan agar proses pemeliharaan dapat dilakukan secara efektif. Pada dasarnya kondisi sebuah transformator daya dapat diketahui berdasarkan beberapa metode seperti DGA (Dissolve Gas Analysis), pengujian minyak trafo, serta furan.

Metode DGA memungkinkan bagi teknisi operator dalam mengetahui adanya kontaminan pada minyak transformator daya. Kadar gas kontaminan dapat menjadi indikator kondisi sebuah transformator daya untuk dapat beroperasi secara normal atau tidak [2]. Pada sisi yang lain adanya pengujian pada transformator daya baik pengujian fisik, pengujian elektrik dan pengujian kimia dapat memberikan data penting mengenai kondisi transformator daya. Pada pengujian fisik akan diperoleh kekuatan minyak transformator dalam menahan tekanan fisik [3]. Pada pengujian dapat diperoleh informasi mengenai breakdown voltage yang untuk mengetahui tegangan yang dapat diizinkan beroperasi pada transformator daya. Pengujian kimia berkontribusi dalam memberikan informasi mengenai tingkat keasaman serta kandungan air dalam minyak transformator yang dapat memicu adanya elektron bebas sebagai penghantar listrik dalam isolator [4]. Selain itu adanya furan yang merupakan salah satu kontaminan dalam minyak transformator daya dapat memberikan informasi mengenai estimasi umur kertas isolasi.

Dalam setiap metode yang digunakan dalam pengujian transformator daya memiliki tujuan tertentu mengenai bagian yang ingin dilakukan pengecekan. Diagnosis kondisi keseluruhan sebuah transformator dapat dilakukan dengan menggunakan metode indeks kesehatan transformator daya yang melibatkan seluruh pengujian pada masing-masing bagian[1]. Dengan menggunakan metode tersebut memungkinkan dalam mengetahui kapan transformator daya harus dilakukan pemeliharaan yang berupa pergantian komponen secara akurat. Namun penggunaan keseluruhan hasil pengujian transformator daya berdampak dalam proses diagnosis yang harus dilakukan dalam waktu yang lama. Selain itu akan dibutuhkan biaya yang tinggi karena banyaknya pengujian yang harus dilakukan dalam satu kali diagnosis.

Peninjauan pada sisi yang lain, seiring dengan perkembangan komputer saat ini mulai dikem-

bangkan metode komputasi dalam mengelola sebuah data. Metode tersebut dikenal dengan istilah *Machine Learning* [5], yakni algoritma komputer yang disusun secara matematis untuk mempelajari sebuah data. Dalam perkembangannya *Machine Learning* telah mengalami banyak perbaikan hingga melahirkan metode baru yang meniru sistem kerja syaraf manusia yang dikenal dengan algoritma *Artificial Neural Network* (ANN) [6]. Pengembangan dari ANN telah banyak disesuaikan dengan jenis data yang diolah diantaranya dalam mengolah data sekuensial adalah *Recurrent Neural Network* (RNN). Data sekuensial merupakan data yang tersusun pada pola berurutan dan saling berkaitan contohnya data yang berkaitan dengan waktu. Beberapa implementasi dari RNN adalah pada prediksi beban listrik [7, 8, 9], pengenalan suara [10, 11], atau dalam memprediksi hujan [12]. Secara sederhana RNN tidak mampu menangani data dengan deret yang panjang karena adanya pengaruh *vanishing gradient*. Modifikasi pada RNN melahirkan metode baru yakni *Long Short-Term Memory* (LSTM) yang dapat mengingat semua data walaupun pada deret yang panjang sehingga dapat memprediksi secara terus menerus [13].

Merujuk pada permasalahan di atas memperlihatkan adanya sebuah solusi dalam metode diagnosis indeks kesehatan transformator daya. Dengan adanya data yang telah terkumpul pada penggunaan metode indeks kesehatan transformator daya dapat dijadikan sebuah objek data yang dapat dipelajari menggunakan *Machine learning*. Hal ini memungkinkan dalam membuat sebuah sistem yang dapat menerima *input* dengan beberapa pengujian saja yang dapat memberikan *output* diagnosis indeks kesehatan transformator. Pada tugas akhir ini akan dirancang sebuah model LSTM yang menyesuaikan terhadap data pengujian transformator daya. Perancangan dilakukan dengan memodifikasi arsitektur LSTM sehingga diperoleh akurasi yang tinggi dalam mendiagnosis indeks kesehatan transformator daya.

## 1.2 Rumusan Masalah

Merujuk pada latar belakang yang telah disampaikan, maka diperoleh rumusan masalah sebagai berikut:

1. Bagaimana perancangan sistem LSTM sehingga dapat mengklasifikasikan indeks kesehatan transformator daya dengan akurasi yang tinggi dan dengan waktu yang lebih cepat?
2. Bagaimana pengaruh hyperparameter dalam meningkatkan performa dari sistem yang dirancang?

## 1.3 Batasan Masalah

Agar perancangan yang diharapkan sesuai dan dapat tercapai, maka dalam perancangan sistem tersebut, ditentukan ruang lingkup perancangan sebagai berikut:

1. Perancangan model metode Long Short Term Memory (LSTM) dilakukan pada lingkup klasifikasi pada data pengujian transformator daya
2. Hasil perancangan dapat diimplementasikan untuk diagnosis indeks kesehatan transformator daya dengan parameter *input* yang dibutuhkan sesuai dengan dataset yang digunakan

## 1.4 Tujuan Perancangan

Adapun tujuan perancangan ini terdiri dari:

1. Merancang sistem diagnosa indeks kesehatan pada transformator daya menggunakan metode LSTM sehingga diperoleh arsitektur yang optimal.
2. Menganalisis kemampuan dari hasil perancangan sistem yang dalam mendiagnosis indeks kesehatan transformator daya.

### 1.5 Manfaat Perancangan

1. Dapat melakukan pemeliharaan (maintenance) dini pada transformator daya untuk mencegah terjadinya gangguan pada transformator daya.
2. Dapat menjaga performa dari transformator daya agar dapat bekerja secara normal.
3. Dapat meminimalisir biaya pemeliharaan karena dapat terjadwal dengan optimal.

### 1.6 Waktu Pelaksanaan Perancangan

Pada tugas akhir ini akan dikerjakan dari proses pengajuan hingga selesai dilakukan dalam 22 minggu terhitung dari bulan januari 2021 hingga Mei 2021. Proses seluruh kegiatan disajikan pada tabel 1.1.

Tabel 1.1. Waktu Pelaksanaan Tugas Akhir

No	Kegiatan	Minggu ke-																					
		1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22
1	Penyusunan proposal TA																						
2	Pengumpulan Referensi																						
3	Pendaftaran TA																						
4	Pengumpulan data																						
5	Penyusunan dan perancangan sistem																						
6	Seminar Kemajuan																						
7	Penyusunan dokumen akhir																						
8	Pendaftaran sidang TA																						
9	Sidang TA																						



## BAB II

### TINJAUAN PUSTAKA

#### 2.1 Transformator Daya

Transformator daya merupakan salah satu peralatan tenaga listrik yang berfungsi dalam men-trasmisikan daya listrik dengan cara menaikkan dan menurunkan tegangan listrik [14]. Hal ini bertujuan dalam mengurangi rugi-rugi daya yang dikarenakan adanya impedansi yang timbul akibat jarak transmisi yang panjang dapat dikurangi dengan menaikkan tegangan. Transformator daya ditempatkan pada sisi pembangkitan untuk menaikkan tegangan dan pada sisi penerimaan untuk menurunkan tegangan. Merujuk pada standar PLN 61 : 1997 pengelompokan transformator yakni berdasarkan tegangan operasinya yang melebihi 20 kV [14]. Karena beroperasi pada daya dan tegangan tinggi maka diperlukan sistem pengamanan pada transformator daya sehingga dapat bekerja dengan aman dan terhindar dari adanya gangguan sistem tenaga listrik. Sistem pengamanan pada transformator daya ialah dengan menggunakan bahan dielektrik cair yakni minyak transformator serta berupa dielektrik pada berupa kertas . Selain dalam menahan tegangan yang tinggi adanya minyak transformator juga berfungsi dalam menghantarkan panas dari dalam akibat rugi-rugi daya ke udara bebas sehingga panas berlebih dapat dicegah [15].


#### 2.2 Indeks Kesehatan Trafo

Dalam sistem jaringan tenaga listrik pada umumnya transformator daya yang digunakan saat beroperasi yang memiliki kondisi yang baik agar terhindar dari gangguan. Kondisi sebuah transformator secara keseluruhan dapat dievaluasi dengan sebuah metode yakni indeks kesehatan transformator [16]. Metode ini merupakan hasil kombinasi data hasil inspeksi lapangan, selama beroperasi maupun hasil pengujian transformator daya di laboratorium atau lapangan [17]. Pengujian pada transformator daya dibagi atas pengujian elektrik, pengujian kimia, dan pengujian fisik. Metode-metode yang sering digunakan pada transformator daya diantaranya adalah *Dissolve Gas Analysis* (DGA), kualitas minyak transformator, furan, faktor daya, pemantauan *tap changer*, riwayat pembebanan serta data pemeliharaan [1].

##### 2.2.1 *Dissolve Gas Analysis* (DGA)

DGA merupakan salah satu metode yang digunakan dalam mendeteksi adanya gangguan pada transformator daya. Dalam kondisi normal dielektrik cair pada transformator daya tidak mengalami dekomposisi dengan cepat. Namun jika terjadi adanya gangguan termal atau elektrik dapat mempercepat laju dekomposisi pada dielektrik. Proses dekomposisi dapat menghasilkan gas kontaminan yang dapat mengubah sifat konduktivitas dari isolator yang dapat memicu adanya gangguan lanjutan. Secara umum terdapat beberapa jenis gas hasil dekomposisi yang dilakukan pengecekan diantaranya adalah hidrogen ( $H_2$ ), metana ( $CH_4$ ), asetilen ( $C_2H_2$ ), etilen ( $C_2H_4$ ), etana ( $C_2H_6$ ), selain itu bahan dielektrik pada berupa kertas juga mengalami dekomposisi yang menghasilkan karbon monoksida (CO) dan karbon dioksida ( $CO_2$ ) [18]. Beberapa dari konsentrasi masing-masing gas yang telah diketahui kemudian dapat dianalisis dengan menggunakan segitiga Duval[2]. Hal dapat dilihat pada Gambar 2.1 untuk menentukan jenis gangguan yang terjadi, yang terdiri dari:

- a. Percikan energi tinggi (*High-energy Arching*)
- b. Percikan energi rendah (*Low-energy Arching*)
- c. Peluahan korona (*Corona Discharges*)
- d. Titik panas suhu rendah (*Hot spots*,  $T < 200^{\circ}\text{C}$ )
- e. Titik panas suhu sedang (*Hot spots*,  $200^{\circ}\text{C} < T < 400^{\circ}\text{C}$ )
- f. Titik panas suhu tinggi (*Hot spots*,  $T > 400^{\circ}\text{C}$ )



Gambar 2.1. Segitiga Duval [2]

### 2.2.2 Kualitas Minyak Transformator

Pada sebuah transformator daya peranan minyak adalah sebagai isolator cair, penghantar panas ke udara luar serta pelindung bagian dalam. Adapun fungsi sebagai isolator cair adalah untuk mencegah adanya loncatan listrik keluar karena pada umumnya transformator daya beroperasi pada tegangan tinggi. Kegunaan minyak transformator sebagai penghantar panas adalah untuk menjaga kestabilan suhu transformator karena adanya rugi-rugi daya yang berubah menjadi kalor. Sedangkan sebagai pelindung adalah untuk mencegah adanya reaksi kimia dari logam bagian dalam terhadap oksigen yang dapat menyebabkan adanya korosi [19].

Minyak transformator daya dapat beroperasi dengan baik jika belum melampaui batasan-batasan standar yang ditetapkan di antaranya tingkat keasaman serta kandungan airnya yang dapat diketahui melalui pengujian secara kimia [20]. Selain itu pengujian secara fisik dapat diperoleh *interfacial tension* yang menjadi indikator banyaknya kontaminan polar yang terlarut dalam minyak [14]. Adapun pengujian elektrik dapat membantu mengetahui batas ambang tegangan yang dapat ditahan oleh bahan dielektrik transformator daya, hal ini dengan tegangan tembus (*breakdown voltage*). Semakin tinggi nilai dari tegangan tembusnya maka semakin aman suatu transformator daya untuk dioperasikan. Tegangan tembus terjadi karena adanya elektron bebas pada bahan dielektrik, adanya elektron bebas pada bahan dielektrik disebabkan keberadaan kontaminan baik berupa gas, cair maupun padat pada sistem isolasi. Standar yang dijadikan rujukan untuk mengetahui kondisi minyak transformator adalah IEC 60422-2013 [21].

Tabel 2.1. Standar Pengujian Minyak Tranformator

Parameter Uji	Metode	Score (Si) batas IEC 60422:2013			Weight (Wi)
		Good(1)	Fair (2)	Poor (3)	
Tegangan Tembus (kV/2.5mm)	IEC 156	50	40 - 50	40	3
Kandungan Air (mg/kg)	IEC 60814	20	20 - 30	30	4
Keasaman (mgKOH/g)	C2011K06	0.1	0.15 - 0.2	0.2	1
Interfacial Tension (mN/m)	ISO 6295	28	22 - 28	22	2

### 2.2.3 Pengujian Furan

Seiring menurunnya umur dari minyak transformator daya akan membentuk suatu senyawa kimia yang dikenal dengan furan. Pembentukan furan juga disebabkan adanya suhu yang tinggi serta proses oksidasi senyawa asam. kerusakan akibat peningkatan konsentrasi di udara serta keberadaan oksigen dapat meningkatkan proses pembentukan furan. Keberadaan furan dapat menjadi acuan mengenai umur dari dielektrik padat yang berupa kertas. Standar pengujian furan disajikan pada Tabel 2.2 [14].

Tabel 2.2. Standar Pengujian Furan

No	2 FAL saat 55°C (ppb)	Estimasi Umur Kertas (%)	Keterangan
1	58	100	Penuaan Normal
2	130	90	
3	292	79	
4	654	66	Percepatan Penuaan
5	1464	50	
6	1720	46	
7	2021	42	
8	2374	38	Daerah Peringatan : Penuaan Tidak Normal
9	2789	33	
10	3277	29	
11	3851	24	Sangat Rentan Gangguan
12	4524	19	
13	5315	13	Akhir Pemakaian Kertas
14	6245	7	
15	7337	0	

## 2.3 Machine Learning

Machine learning merupakan salah satu metode yang digunakan dalam mempelajari pola serangkaian data dengan proses komputasi digital [5]. Secara sederhana algoritma dirancang untuk digunakan dalam mempelajari suatu data kemudian dapat melakukan prediksi berdasarkan *input* baru yang diberikan. Berdasarkan cara belajarnya terdapat pengelompokan pada *machine learning* yakni *supervised learning* dan *unsupervised learning*. Pada *supervised learning* model dapat mempelajari data yang memiliki fitur yang dilengkapi dengan data target, sedangkan pada *unsupervised learning* model belajar tanpa menggunakan adanya data target sehingga pada proses prediksi model akan

memberikan keluaran berupa pengelompokan data [22].

*Machine Learning* telah mengalami banyak modifikasi untuk menyesuaikan jenis data yang diolah. Arsitektur baru dari *machine learning* yang banyak digunakan saat ini berupa algoritma yang meniru sistem kerja syaraf manusia yang dikenal dengan algoritma *Artificial Neural Network* (ANN) [6]. Dengan menggunakan ANN sistem memungkinkan dalam mengenali objek dalam sebuah gambar merupakan salah satu implementasinya. Adapun pada pengolahan data yang bersifat *time series* atau berupa deret ANN dikembangkan agar dapat melakukan sebuah prediksi berdasarkan *input* yang diterima sebelumnya sebagai dasar referensi prediksi ke depan. Model tersebut dikenal dengan *Recurrent Neural Network* dimana setiap *input* yang diterima sebelum dilakukan prediksi akan diproses secara berulang pada satu sel RNN sehingga model dapat mengingat informasi pentingnya [23].

## 2.4 Long Short Term Memory (LSTM)

Pada pemodelan dengan menggunakan metode RNN secara umum memiliki kemampuan dalam membuat prediksi yang dipengaruhi oleh *input* sebelumnya. Namun terdapat kekurangan pada metode tersebut yakni tidak mampu mengatasi dengan seri yang panjang, misalnya pada sebuah data *time series*, RNN akan sulit mengkorelasikan antara data saat ini dengan data yang sangat lampau, akibatnya jika data yang diproses dalam rentang waktu yang lama maka RNN hanya mampu membuat prediksi yang hanya berkaitan pada waktu yang pendek. Kekurangan pada RNN dikarenakan adanya *vanishing gradient*, yakni menghapus data yang tidak berkaitan dengan data baru yang dimasukkan. Adanya kekurangan tersebut maka dibutuhkan suatu metode baru yang dapat mengingat data lampau saat menerima *input* terbaru. LSTM merupakan salah satu turunan dari pemodelan matematis yang digunakan dalam mengenali pola serangkaian data

Kelebihan yang dimiliki LSTM dibandingkan dengan RNN dikarenakan algoritma yang digunakan terdiri dari struktur yang kompleks. Secara umum terdapat 4 bagian pada arsitektur LSTM yakni *forget gate*, *input gate*, *Cell gate*, dan *Output gate*.

### 2.4.1 Forget Gate

Pada *Forget gate* merupakan bagian yang menentukan mengenai informasi pada keluaran sel sebelumnya untuk dipertahankan atau dihapus. Hal ini dilakukan dengan memasukkan keluaran sel sebelumnya yang digabungkan dengan masukan baru ke dalam fungsi aktivasi sigmoid. Informasi akan dipertahankan untuk hasil dari sigmoid dengan nilai 1 dan dihapus untuk keluaran yang bernilai 0. Secara matematis pada *forget gate* digunakan persamaan sebagai berikut:

$$f_t = \sigma_g(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.1)$$

Berdasarkan persamaan (2.1) dapat diketahui pada persamaan tersebut terdapat bentuk  $[h_{t-1}, x_t]$ . Hal ini merupakan operasi penggabungan vektor yakni penggabungan baris pada  $h_{t-1}$  dengan baris pada  $x_t$ .

### 2.4.2 Input Gate

Salah satu kelebihan LSTM adalah dapat mengingat informasi data masukan yang lama. Hal ini dikarenakan karena adanya satu bagian yang berperan dalam memperbarui memori berdasarkan



informasi penting dari masukan baru. Kemampuan ini diperoleh karena ada dua tahapan penting pada *input gate* yakni melalui lapisan *sigmoid* dan *tanh*. lapisan akan memberikan keluaran berupa nilai mana saja yang harus dilakukan pembaruan pada memori sedangkan lapisan *tanh* memberikan keluaran berupa calon ( $\tilde{C}$ ) yang ditambahkan pada memori.

$$i_t = \sigma_i(W_f.[h_{t-1}, x_t] + b_i) \quad (2.2)$$

$$\tilde{C} = \tanh(W_C.[h_{t-1}, x_t] + b_C) \quad (2.3)$$

Hasil perkalian dari dua lapisan pada *input gate* akan menjadi *input* pada memori sebagai pembaruan. pembaruan yang terjadi dalam hanya dalam jumlah yang sedikit, oleh karena itu informasi penting pada data yang lampau akan tetap tersimpan untuk jumlah data yang banyak.

### 2.4.3 Cell gate

*Cell gate* merupakan tempat penyimpanan informasi penting pada setiap data yang diberikan pada LSTM. *cell gate* terdiri dari masukan dari *forget gate* untuk mengurangi informasi yang tidak diperlukan dari semua masukan sebelumnya melalui persamaan (2.1). Kemudian ditambahkan dengan hasil perkalian dari  $i_t$  dan  $\tilde{C}$ .

$$C_t = f_t * C_{t-1} + i_t * \tilde{C} \quad (2.4)$$

Hal utama yang perlu diperhatikan adalah bahwa pada LSTM bagian *cell gate* merupakan lapisan yang saling terhubung, sehingga antar sel yang berjauhan pun dapat terintegrasi. Kondisi ini yang menjadikan LSTM dapat mengatasi permasalahan versi RNN sebelumnya yang diakibatkan adanya *vanishing gradient*.

### 2.4.4 Output Gate

Pada bagian akhir merupakan keluaran dari sel lstm atau dapat berupa hasil prediksi berdasarkan masukan yang diberikan. Keluaran ditentukan oleh memori  $C_t$  dan masukan yang diberikan. Hal ini dilakukan dengan memasukkan  $x_t$  dan keluaran sebelumnya ( $h_{t-1}$ ) pada fungsi *sigmoid*. Hasil dari fungsi *sigmoid* kemudian akan memfilter nilai dari *cell state* yang dapat diteruskan menuju keluaran. Sebelum dikalikan dengan hasil dari gerbang *sigmoid*, *cell state* terlebih dahulu melewati gerbang *tanh* untuk mengubah nilai pada rentang -1 sampai 1. Secara matematis dapat dituliskan sebagai berikut:

$$o_t = \sigma(W_o.[h_{t-1}, x_t] + b_o) \quad (2.5)$$

$$h_t = o_t * \tanh(C_t) \quad (2.6)$$




## BAB III

### KONSEP PERANCANGAN

#### 3.1 Diagram Alir Perancangan

Perancangan sistem dilakukan dalam beberapa tahap untuk menghasilkan sistem yang dapat bekerja dengan baik saat melakukan diagnosis indeks kesehatan pada transformator daya. Pada Gambar 3.1 merupakan tahapan perancangan yang digambarkan dalam diagram alir



Gambar 3.1. Diagram Alir Perancangan Sistem Model LSTM

#### 3.2 Pertimbangan Perancangan

Pada perancangan ini pertimbangan utama penggunaan model LSTM adalah karena pada dasarnya LSTM mampu memprediksi suatu klasifikasi dimana vektor masukan (*input*) yang diberikan akan saling mendukung. Dalam diagnosis indeks kesehatan transformator daya prosesnya dilakukan melalui beberapa hasil pengujian yang berupa pengujian kimia, fisik, maupun elektrik. Data hasil pengujian pada dasarnya saling berkaitan, misalnya pengujian tegangan tembus erat kaitanya dengan adanya kontaminasi pada bahan dielektrik, di sisi lain pengujian secara kimia dilakukan dengan menggunakan DGA untuk mengetahui kandungan gas yang terlarut. Pada proses pembuatan model LSTM *input* yang akan digunakan nantinya adalah data hasil percobaan pengujian transformator daya. Merujuk pada sifat model LSTM yang mengingat semua *input* untuk mendapatkan hasil prediksi yang mak-

simal, maka penggunaan model ini memiliki kecocokan terhadap proses diagnosis indeks kesehatan transformator daya.

Menggunakan metode LSTM dalam memodelkan diagnosis indeks kesehatan transformator tidak dapat dilakukan secara langsung. Pemodelan harus disesuaikan dengan sistem yang akan diterapkan. Oleh karena itu akan dilakukan beberapa percobaan untuk memodifikasi arsitektur pada LSTM. Terdapat beberapa pertimbangan utama dalam menentukan baik dan tidaknya suatu model dapat dilakukan dengan melihat performa dari sistem tersebut. Performa sistem pada algoritma machine learning umumnya dapat ditentukan dengan menggunakan confusion matrix. Dari confusion matrix selanjutnya akan diperoleh akurasi, presisi, sensitifitas, specificity, dan F1 score.

Tabel 3.1. *Confussion Matrrix*

Confussion Matrix		Nilai Aktual	
		Positif	Negatif
Nilai Terprediksi	Positif	TP	FP
	Negatif	FN	TN

### 3.2.1 Akurasi

Nilai akurasi menunjukkan seberapa akurat dalam memprediksi suatu nilai. Dalam confusion matrix akurasi merupakan rasio prediksi Benar (positif dan negatif) dengan total keseluruhan data. Algoritma machine learning dipilih berdasarkan akurasi yang tinggi jika dataset yang digunakan memiliki jumlah data False Negative (FN) dan False Positive (FP) yang sangat mendekati (symmetric).

### 3.2.2 Presisi

Nilai dari presisi merupakan perbandingan data yang terprediksi benar yang bernilai positif terhadap keseluruhan jumlah data yang bernilai positif dan yang bernilai negatif. Pemilihan nilai presisi sebagai bahan pertimbangan dalam menentukan model yang terbaik jika diinginkan terjadinya prediksi benar yang bernilai positif, serta sangat menghindari terjadinya hasil prediksi yang salah dan bernilai negatif.

### 3.2.3 Sensitifitas (*recall*)

Sensitifitas merupakan perbandingan data yang terprediksi benar yang bernilai positif dibandingkan terhadap keseluruhan data yang terprediksi benar dan bernilai positif. Pertimbangan pemilihan nilai ini diambil jika model yang diinginkan merupakan model yang memiliki kecenderungan memprediksi salah bernilai positif dibandingkan dengan hasil prediksi salah yang bernilai negatif.

### 3.2.4 Spesificitiy

Specificity merupakan perbandingan antara data yang terprediksi dengan benar yang bernilai negatif terhadap keseluruhan data yang bernilai negatif. Pemilihan nilai ini didasarkan jika model tidak diinginkan terjadinya hasil prediksi yang bernilai positif.

### 3.2.5 *F1 Score*

F1 Score merupakan perbandingan rata-rata dari presisi dan recall yang dilakukan pembobotan. Nilai dari F1 Score dijadikan sebagai pertimbangan baik dan tidaknya suatu algoritma machine learning jika nilai dari hasil prediksi salah dengan nilai negatif (FN) dan False positif (FP) berbeda jauh.

### 3.2.6 Waktu Pelatihan dan Pengujian

Waktu training merupakan durasi waktu yang dibutuhkan dalam proses pelatihan untuk mendapatkan nilai performa tertinggi dalam satu data set. Waktu testing merupakan waktu yang dibutuhkan dari suatu sistem dalam memprediksi dari *input* yang belum pernah di berikan pada sistem. Kedua parameter ini dapat dijadikan acuan sebagai baik dan buruknya suatu sistem biasanya untuk waktu pemrosesan yang lebih singkat tidak dibutuhkan komputasi yang besar sehingga spesifikasi hardware yang digunakan tidak terlalu tinggi.

## 3.3 Perancangan Model LSTM

Sistem diagnosis indeks kesehatan transformator daya yang diharapkan pada dasarnya adalah yang memiliki performa yang baik. Sehingga pada perancangan ini dilakukan percobaan untuk mendapatkan model dari LSTM dengan akurasi minimal 85% baik pada proses pelatihan dan pengujian. Indikator yang digunakan dalam penilaian baik dan buruknya sistem adalah nilai *loss* serta akurasi sistem. Nilai *loss* terbaik adalah yang minimum, sedangkan akurasi ditentukan yang terbesar. Untuk mendapatkan model dengan performa yang diharapkan baik dilakukan beberapa modifikasi pada arsitektur pada LSTM diantaranya jumlah *neuron* pada setiap sel serta penggunaan banyaknya *layer* LSTM yang digunakan. Di sisi lain perlakuan pada pembagian dataset juga menjadi fokus pembahasan pada perancangan.

### 3.3.1 Jumlah Neuron

Model LSTM pada dasarnya merupakan pengembangan dari algoritma *Neural Network* sehingga jumlah neuron akan mempengaruhi kapasitas belajar jaringan. Secara umum, lebih banyak neuron akan dapat mempelajari lebih banyak struktur dari dataset namun konsekuensinya akan membutuhkan waktu pelatihan yang lebih lama. Kapasitas belajar yang lebih besar juga menimbulkan masalah kemungkinan *overfitting* pada data pelatihan sehingga akan sensitif terhadap adanya data yang memiliki *noise*.

### 3.3.2 Multilayer layer LSTM

Jumlah *layer* LSTM secara umum digunakan dalam meningkatkan performa sistem karena secara sederhana jika pada penggunaan *single layer* nilai prediksi hanya mempertimbangkan masukan masing-masing sel serta keluaran hanya ditentukan oleh sel terakhir. Pada penggunaan *multilayer* keluaran akhir sistem akan mempertimbangkan keluaran setiap sel pada layer sebelumnya. Penambahan *layer* LSTM akan menambah kapasitas belajar dari model yang akan membuat proses pelatihan cenderung lebih lama. Sehingga pada perancangan penambahan *layer* tidak dilakukan pada jumlah

yang banyak agar sistem cepat dalam hal komputasi namun performa masih memiliki akurasi yang tinggi.

### 3.3.3 Rasio Dataset

Pada proses pelatihan dan pengujian pada *machine learning* jumlah dataset yang digunakan dapat mempengaruhi performa sistem. Semakin banyak jumlah dataset yang digunakan dalam proses pelatihan secara ideal dapat memperbaiki performa karena model dapat terlatih dengan banyaknya data. Namun disisi lain dalam proses validasi diperlukan sebagian dari dataset untuk menguji sistem ketika dihadapkan pada data yang belum pernah dikenali. Sehingga diperlukan rasio yang tepat agar model yang dihasilkan memiliki performa yang baik pada proses pelatihan dan pengujian. Pada perancangan ini akan dilakukan beberapa percobaan dengan variabel bebas berupa rasio dataset pelatihan dan pengujian.

### 3.4 Analisis Teknis

Hasil dari perancangan ini merupakan sebuah pemodelan indeks kesehatan transformator. Dalam implementasinya model akan memberikan keluaran berupa indeks kesehatan transformator dengan menggunakan *input* berupa hasil pengujian laboratorium atau lapangan. *Input* yang digunakan berupa fitur data yang digunakan dalam proses pelatihan dan pengujian. Selama proses perancangan jumlah *input* yang digunakan tidak sebanyak yang digunakan dalam menentukan indeks kesehatan transformator secara manual dengan menggunakan pemodelan matematika. Oleh karena itu pada proses pengolahan data pertama kali akan dilakukan perhitungan indeks kesehatan transformator daya yang merupakan data target dengan menggunakan persamaan matematis. Pada tahap selanjutnya data yang akan digunakan dalam percobaan baik pada pelatihan maupun pada pengujian ialah data yang sudah direduksi beberapa fiturnya. Reduksi fitur data dilakukan pada data yang memiliki banyak data pencilaan, sehingga data yang terdistribusi dengan baik saja yang akan dilakukan dalam proses perancangan.

Pada dasarnya model dirancang untuk tetap memberikan keluaran berupa diagnosis indeks kesehatan transformator daya tanpa menggunakan semua data pengujian laboratorium atau lapangan. Model hasil perancangan ini merupakan sebuah komputasi dalam sebuah program berbasis bahasa pemrograman python. Hal ini tentu akan sulit dipahami bagi orang yang belum mengenal bahasa pemrograman. Oleh karena itu pada tahapan akhir perancangan ini model yang dihasilkan akan diteruskan pada pembuatan tampilan antar muka sistem. Untuk memenuhi kebutuhan tersebut model dikonversikan ke dalam bentuk aplikasi baik pada perangkat portabel maupun yang berbasis *Personal Computer* (PC). Desain aplikasi yang dirancang adalah berupa tampilan beberapa kolom *input* untuk memasukkan data hasil pengujian transformator daya, kemudian setelah semua *input* diberikan, pengguna akan memberikan perintah berupa tombol untuk memproses *input* agar sistem dapat menampilkan hasil diagnosis indeks kesehatan transformator daya. Penggunaan metode tersebut secara signifikan dapat mengurangi waktu dalam menentukan indeks kesehatan transformator daya yang dengan cara konvensional membutuhkan data pengujian yang lengkap. Sehingga diharapkan dapat mengurangi jumlah pengujian transformator daya dan secara tidak langsung berperan dalam mengurangi biaya dalam pemeliharaan transformator daya.

### 3.5 Peralatan dan Bahan

Pada perancangan ini dalam mendukung proses analisis menggunakan metode LSTM digunakan peralatan dan bahan yang ditunjukkan pada Tabel 3.2.

Tabel 3.2. Alat dan Bahan

No	Alat dan Bahan	Jumlah
1	Personal Komputer (PC)	1 Set
2	<i>Executable Code</i>	1 Buah
3	<i>Library Python</i>	1 Set





## DAFTAR PUSTAKA

- [1] A. Jahromi, R. Piercy, S. Cress, J. Service, and W. Fan, "An approach to power transformer asset management using health index," *IEEE Electrical Insulation Magazine*, vol. 25, no. 2, pp. 20–34, 2009.
- [2] M. Duval, "Dissolved gas analysis: It can save your transformer," *IEEE Electrical Insulation Magazine*, vol. 5, no. 6, pp. 22–27, 1989.
- [3] N. A. Baka, A. Abu-Siada, S. Islam, and M. F. El-Naggar, "A new technique to measure interfacial tension of transformer oil using uv-vis spectroscopy," *IEEE Transactions on Dielectrics and Electrical Insulation*, vol. 22, no. 2, pp. 1275–1282, 2015.
- [4] M. A. Wahab, M. Hamada, A. Zeitoun, and G. Ismail, "Novel modeling for the prediction of aged transformer oil characteristics," *Electric Power Systems Research*, vol. 51, no. 1, pp. 61–70, 1999.
- [5] M. I. Jordan and T. M. Mitchell, "Machine learning: Trends, perspectives, and prospects," *Science*, vol. 349, no. 6245, pp. 255–260, 2015.
- [6] P. J. Braspenning, F. Thuijsman, and A. J. M. M. Weijters, *Artificial neural networks: an introduction to ANN theory and practice*. Springer Science & Business Media, 1995, vol. 931.
- [7] A. Tokgöz and G. Ünal, "A rnn based time series approach for forecasting turkish electricity load," in *2018 26th Signal Processing and Communications Applications Conference (SIU)*. IEEE, 2018, pp. 1–4.
- [8] X. Tang, Y. Dai, Q. Liu, X. Dang, and J. Xu, "Application of bidirectional recurrent neural network combined with deep belief network in short-term load forecasting," *IEEE Access*, vol. 7, pp. 160 660–160 670, 2019.
- [9] A. Deihimi and H. Showkati, "Application of echo state networks in short-term electric load forecasting," *Energy*, vol. 39, no. 1, pp. 327–340, 2012.
- [10] Y. Miao, M. Gowayyed, and F. Metze, "Eesen: End-to-end speech recognition using deep rnn models and wfst-based decoding," in *2015 IEEE Workshop on Automatic Speech Recognition and Understanding (ASRU)*. IEEE, 2015, pp. 167–174.
- [11] A. Amberkar, P. Awasarmol, G. Deshmukh, and P. Dave, "Speech recognition using recurrent neural networks," in *2018 International Conference on Current Trends towards Converging Technologies (ICCTCT)*. IEEE, 2018, pp. 1–4.
- [12] H. V. Habi and H. Messer, "Rnn models for rain detection," in *2019 IEEE International Workshop on Signal Processing Systems (SiPS)*. IEEE, 2019, pp. 184–188.
- [13] F. A. Gers, J. Schmidhuber, and F. Cummins, "Learning to forget: Continual prediction with lstm," 1999.
- [14] G. L. Sutaryono, "Analisa indeks kesehatan transformator daya berbasis neural network untuk mereduksi jumlah test pada trafo," Ph.D. dissertation, Institut Teknologi Sepuluh Nopember, 2015.
- [15] C. Krause, "Power transformer insulation—history, technology and design," *IEEE Transactions on Dielectrics and Electrical Insulation*, vol. 19, no. 6, pp. 1941–1947, 2012.

- [16] H. Nurcahyanto, J. M. Nainggolan, I. M. Ardita, and C. Hudaya, "Analysis of power transformer's lifetime using health index transformer method based on artificial neural network modeling," in *2019 International Conference on Electrical Engineering and Informatics (ICEEI)*. IEEE, 2019, pp. 574–579.
- [17] F. Ortiz, I. Fernandez, A. Ortiz, C. J. Renedo, F. Delgado, and C. Fernandez, "Health indexes for power transformers: a case study," *IEEE Electrical Insulation Magazine*, vol. 32, no. 5, pp. 7–17, 2016.
- [18] M. Ahmed, M. Geliel, and A. Khalil, "Power transformer fault diagnosis using fuzzy logic technique based on dissolved gas analysis," in *21st Mediterranean Conference on Control and Automation*. IEEE, 2013, pp. 584–589.
- [19] P. PLN, "Panduan pemeliharaan trafo tenaga," *Jakarta: PT PLN (Persero) Penyaluran dan Pusat Pengatur Beban Jawa Bali*, 2003.
- [20] I. T. Committee *et al.*, "Ieee std. c57. 106–2006, ieee guide for acceptance and maintenance of insulating oil in equipment," 2007.
- [21] I. Standard *et al.*, "Mineral insulating oils in electrical equipment–supervision and maintenance guidance," *BS EN*, vol. 60422, 2013.
- [22] E. Alpaydin, *Introduction to machine learning*. MIT press, 2020.
- [23] L. R. Medsker and L. Jain, "Recurrent neural networks," *Design and Applications*, vol. 5, 2001.