

BAB I

PENDAHULUAN

1.1 Latar Belakang

Transformator daya merupakan salah satu peralatan dalam sistem kelistrikan yang memiliki peran fundamental. Dalam pengoperasiannya transformator berperan dalam menaikkan serta menurunkan tegangan pada jaringan transmisi. Apabila transformator daya tidak dapat bekerja dengan baik maka dapat menurunkan kualitas listrik atau lebih lanjut dapat menyebabkan terhentinya pelayanan listrik yang diterima oleh konsumen. Selain itu apabila transformator daya dalam kondisi tidak normal dapat membuat rugi-rugi daya menjadi semakin besar, hal ini tentunya dapat merugikan penyedia listrik. Menurut manufaktur usia transformator daya diperkirakan antara 25-40 tahun, tetapi terkadang terdapat transformator yang usianya di bawah range usia minimal telah rusak [1].

Pemeliharaan transformator daya sangat penting dilakukan untuk memastikan agar selalu dapat beroperasi dengan baik. Namun jika pemeliharaan dilakukan dengan intensitas yang tinggi tentunya dapat membuat dana yang harus dialokasikan semakin besar. Sedangkan diketahui bahwa transformator merupakan komponen yang membutuhkan hampir 60% dari biaya total pada gardu induk [1]. Sehingga diperlukan penjadwalan agar proses pemeliharaan dapat dilakukan secara efektif. Pada dasarnya kondisi sebuah transformator daya dapat diketahui berdasarkan beberapa metode seperti DGA (Dissolve Gas Analysis), pengujian minyak trafo, serta furan.

Metode DGA memungkinkan bagi teknisi operator dalam mengetahui adanya kontaminan pada minyak transformator daya. Kadar gas kontaminan dapat menjadi indikator kondisi sebuah transformator daya untuk dapat beroperasi secara normal atau tidak. Pada sisi yang lain adanya pengujian pada transformator daya baik pengujian fisik, pengujian elektrik dan pengujian kimia dapat memberikan data penting mengenai kondisi transformator daya. Pada pengujian fisik akan diperoleh kekuatan minyak transformator dalam menahan tekanan fisik. Pada pengujian dapat diperoleh informasi mengenai breakdown voltage yang untuk mengetahui tegangan yang dapat diizinkan beroperasi pada transformator daya. Pengujian kimia berkontribusi dalam memberikan informasi mengenai tingkat keasaman serta kandungan air dalam minyak transformator yang dapat memicu adanya elektron bebas sebagai penghantar listrik dalam isolator. Selain itu adanya furan yang merupakan salah satu kontaminan dalam minyak transformator daya dapat memberikan informasi mengenai estimasi umur kertas isolasi.

Data hasil pengujian transformator daya yang dikumpulkan pada waktu yang lama akan memberikan karakteristik tertentu. Hal ini tentunya memberikan informasi solutif dalam mengidentifikasi kondisi transformator daya. Banyaknya data yang terkumpul akan sangat sulit dalam melakukan analisis dengan cara konvensional. Adanya metode komputasi modern memberikan dapat mempermudah dalam melakukan perhitungan dalam jumlah yang besar. Hal ini melahirkan suatu metode baru dalam mengenali karakteristik dari suatu data melalui perhitungan yang matematis. Metode pengenalan karakteristik data saat ini dikenal dengan Machine Learning, istilah yang diumpamakan komputer dalam mempelajari suatu data.

Seiring dengan berjalannya waktu Machine Learning telah mengalami banyak perubahan yang menciptakan istilah baru yakni Deep Learning. Pada algoritma tersebut dibentuk dengan menirukan

jaringan saraf pada manusia sehingga dapat mempelajari suatu data dengan baik. Perkembangan Deep Learning sendiri sudah banyak dilakukan yang menyesuaikan dengan data yang akan diproses, salah satunya adalah *Long Short Term Memory* (LSTM). Algoritma ini dibentuk untuk menangani data yang bersifat sekuensial seperti halnya data yang selalu berubah seiring dengan berjalannya waktu. Keberadaan LSTM dapat menjadi solusi dalam memproses data hasil pengujian pada transformator daya sehingga hasilnya dapat memberikan klasifikasi mengenai indeks kesehatan transformator daya. Hasil klasifikasi indeks kesehatan selanjutnya dapat dimanfaatkan dalam pemeliharaan transformator daya sehingga dapat dilakukan lebih efektif.

1.2 Rumusan Masalah

Merujuk pada latar belakang yang telah disampaikan, maka diperoleh rumusan masalah sebagai berikut:

1. Bagaimana perancangan sistem LSTM sehingga dapat mengklasifikasikan indeks kesehatan transformator daya dengan akurasi yang tinggi dan dengan waktu yang lebih cepat?
2. Bagaimana pengaruh hyperparameter dalam meningkatkan performa dari sistem yang dirancang?

1.3 Batasan Masalah

Agar perancangan yang diharapkan sesuai dan dapat tercapai, maka dalam perancangan sistem tersebut, ditentukan ruang lingkup perancangan sebagai berikut:

1. Perancangan model metode Long Short Term Memory (LSTM) dilakukan pada lingkup klasifikasi pada data pengujian transformator daya
2. Hasil perancangan dapat diimplementasikan untuk diagnosis indeks kesehatan transformator daya dengan parameter input yang dibutuhkan sesuai dengan dataset yang digunakan

1.4 Tujuan Penelitian

Adapun tujuan perancangan ini terdiri dari:

1. Merancang sistem diagnosa indeks kesehatan pada transformator daya menggunakan metode LSTM dengan akurasi di atas 80%.
2. Dapat menentukan pengaruh hyperparameter dari metode LSTM sehingga diperoleh sistem yang diharapkan.

1.5 Manfaat Perancangan

1. Dapat melakukan pemeliharaan (maintenance) dini pada transformator daya untuk mencegah terjadinya gangguan pada transformator daya.
2. Dapat menjaga performa dari transformator daya agar dapat bekerja secara normal.
3. Dapat meminimalisir biaya pemeliharaan karena dapat terjadwal dengan optimal.



BAB II

TINJAUAN PUSTAKA

2.1 Transformator Daya

Transformator daya merupakan salah satu peralatan tenaga listrik yang berfungsi dalam men-trasmisikan daya listrik dengan cara menaikkan dan menurunkan tegangan listrik untuk mengurangi rugi-rugi daya. hal ini dikarenakan rugi-rugi daya akibat impedansi yang timbul akibat jarak transmisi yang panjang dapat dikurangi dengan menaikkan tegangan. oleh karena itu dibutuhkan transformator pada sisi pembangkitan untuk menaikkan tegangan dan pada sisi penerimaan untuk menurunkan tegangan.

$$L(x, W) = \frac{1}{N} \sum_{i=0}^N l(x_i, W) \quad (2.1)$$

2.2 Indeks Kesehatan Trafo

Dalam sistem jaringan tenaga listrik pada umumnya transformator daya yang digunakan saat beroperasi yang memiliki kondisi yang baik agar terhindar dari gangguan. kondisi sebuah transformator secara keseluruhan dapat dievaluasi dengan sebuah metode yakni indeks kesehatan transformator [2]. metode ini merupakan hasil kombinasi data hasil inspeksi lapangan, selama beroperasi maupun hasil pengujian transformator daya di laboratorium atau lapangan [3]. Pengujian pada transformator daya dibagi atas pengujian elektrik, pengujian kimia, dan pengujian fisik. Metode-metode yang sering digunakan pada transformator daya diantaranya adalah *Dissolve Gas Analysis* (DGA), kualitas minyak transformator, furan, faktor daya, pemantauan *tap changer*, riwayat pembebanan serta data pemeliharaan [1].

2.2.1 *Dissolve Gas Analysis* (DGA)

DGA merupakan salah satu metode yang digunakan dalam mendeteksi adanya gangguan pada transformator daya. Dalam kondisi normal dielektrik cair pada transformator daya tidak mengalami dekomposisi dengan cepat. Namun jika terjadi adanya gangguan termal atau elektrik dapat mempercepat laju dekomposisi pada dielektrik. Proses dekomposisi dapat menghasilkan gas kontaminan yang dapat mengubah sifat konduktivitas dari isolator yang dapat memicu adanya gangguan lanjutan. Secara umum terdapat beberapa jenis gas hasil dekomposisi yang dilakukan pengecekan diantaranya adalah hidrogen,

2.3 *Machine Learning*

Machine learning merupakan salah satu metode yang digunakan dalam memodelkan pola serangkaian data untuk membuat prediksi pada input yang sama atau menyerupai

2.4 Long Short Term Memory (LSTM)

Pada pemodelan dengan menggunakan metode RNN secara umum memiliki kemampuan dalam membuat prediksi yang dipengaruhi oleh input sebelumnya. Namun terdapat kekurangan pada metode tersebut yakni tidak mampu mengatasi dengan seri yang panjang. misalnya pada sebuah data *time series*, RNN akan sulit mengkorelasikan antara data saat ini dengan data yang sangat lampau, akibatnya jika data yang diproses dalam rentang waktu yang lama maka RNN hanya mampu membuat prediksi yang hanya berkaitan pada waktu yang pendek. kekurangan pada RNN dikarenakan adanya *vanishing gradient*, yakni menghapus data yang tidak berkaitan dengan data baru yang dimasukkan. Adanya kekurangan tersebut maka dibutuhkan suatu metode baru yang dapat mengingat data lampau saat menerima input terbaru. LSTM merupakan salah satu turunan dari pemodelan matematis yang digunakan dalam mengenali pola serangkaian data

kelebihan yang dimiliki LSTM dibandingkan dengan RNN dikarenakan algoritma yang digunakan terdiri dari struktur yang kompleks. Secara umum terdapat 4 bagian pada arsitektur LSTM yakni *forget gate*, *input gate*, *Cell gate*, dan *Output gate*.

2.4.1 Forget Gate

Pada *Forget gate* merupakan bagian yang menentukan mengenai informasi pada keluaran sel sebelumnya untuk dipertahankan atau dihapus. hal ini dilakukan dengan memasukkan keluaran sel sebelumnya yang digabungkan dengan masukan baru ke dalam fungsi aktivasi sigmoid. Informasi akan dipertahankan untuk hasil dari sigmoid dengan nilai 1 dan dihapus untuk keluaran yang bernilai 0. secara matematis pada *forget gate* digunakan persamaan sebagai berikut:

$$f_t = \sigma_g(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.2)$$

berdasarkan persamaan (2.2) dapat diketahui bahwa dengan persamaan tersebut terdapat bentuk $[h_{t-1}, x_t]$. Hal ini merupakan operasi penggabungan vektor yakni penggabungan baris pada h_{t-1} dengan baris pada x_t

2.4.2 Input Gate

Salah satu kelebihan LSTM adalah dapat mengingat informasi data masukan yang lama. Hal ini dikarenakan karena adanya satu bagian yang berperan dalam memperbarui memori berdasarkan informasi penting dari masukan baru. kemampuan ini diperoleh karena ada dua tahapan penting pada *input gate* yakni melalui lapisan *sigmoid* dan *tanh*. lapisan akan memberikan keluaran berupa nilai mana saja yang harus dilakukan pembaruan pada memori sedangkan lapisan *tanh* memberikan keluaran berupa calon (\tilde{C}) yang ditambahkan pada memori.

$$i_t = \sigma_i(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.3)$$

$$\tilde{C} = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (2.4)$$

Hasil perkalian dari dua lapisan pada *input gate* akan menjadi input pada memori sebagai pembaruan. pembaruan yang terjadi dalam hanya dalam jumlah yang sedikit, oleh karena itu informasi penting pada data yang lampau akan tetap tersimpan untuk jumlah data yang banyak.

2.4.3 Cell gate

cell gate merupakan tempat penyimpanan informasi penting pada setiap data yang diberikan pada LSTM. *cell gate* terdiri dari masukan dari *forget gate* untuk mengurangi informasi yang tidak diperlukan dari semua masukan sebelumnya melalui persamaan (2.2). Kemudian ditambahkan dengan hasil perkalian dari i_t dan \tilde{C} .

$$C_t = f_t * C_{t-1} + i_t * \tilde{C} \quad (2.5)$$

Hal utama yang perlu diperhatikan adalah bahwa pada LSTM bagian *cell gate* merupakan lapisan yang saling terhubung, sehingga antar sel yang berjauhan pun dapat terintegrasi. Kondisi ini yang menjadikan LSTM dapat mengatasi permasalahan versi RNN sebelumnya yang diakibatkan adanya *vanishing gradient*.

2.4.4 Output Gate

Pada bagian akhir merupakan keluaran dari sel lstm atau dapat berupa hasil prediksi berdasarkan masukan yang diberikan. Keluaran ditentukan oleh memori C_t dan masukan yang diberikan. Hal ini dilakukan dengan memasukkan x_t dan keluaran sebelumnya (h_{t-1}) pada fungsi *sigmoid*. Hasil dari fungsi *sigmoid* kemudian akan memfilter nilai dari *cell state* yang dapat diteruskan menuju keluaran. Sebelum dikalikan dengan hasil dari gerbang *sigmoid*, *cell state* terlebih dahulu melewati gerbang *tanh* untuk mengubah nilai pada rentang -1 sampai 1. secara matematis dapat dituliskan sebagai berikut:

$$o_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_o) \quad (2.6)$$

$$h_t = o_t * \tanh(C_t) \quad (2.7)$$

Tabel 2.1. Rata-rata loss dan accuracy Model A untuk seluruh round

train_accuracy	0.46846
train_loss	2.71451
val_accuracy	0.47391
val_loss	2.69424

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus. Gambar ?? menunjukkan sudut pandang umum yang digunakan dalam berkomunikasi menggunakan bahasa isyarat, yaitu tampak depan [4]. Sehingga, data gambar yang digunakan di penelitian ini juga memuat gestur Bisindo dari tampak depan, dengan persamaan (2.1), dengan hasil penelitian di Bab ??.

DAFTAR PUSTAKA


- [1] A. Jahromi, R. Piercy, S. Cress, J. Service, and W. Fan, "An approach to power transformer asset management using health index," *IEEE Electrical Insulation Magazine*, vol. 25, no. 2, pp. 20–34, 2009.
- [2] H. Nurcahyanto, J. M. Nainggolan, I. M. Ardita, and C. Hudaya, "Analysis of power transformer's lifetime using health index transformer method based on artificial neural network modeling," in *2019 International Conference on Electrical Engineering and Informatics (ICEEI)*. IEEE, 2019, pp. 574–579.
- [3] F. Ortiz, I. Fernandez, A. Ortiz, C. J. Renedo, F. Delgado, and C. Fernandez, "Health indexes for power transformers: a case study," *IEEE Electrical Insulation Magazine*, vol. 32, no. 5, pp. 7–17, 2016.
- [4] Z. Xiong, A. D. Liveris, and S. Cheng, "Distributed source coding for sensor networks," *IEEE Signal Processing Magazine*, vol. 21, no. 5, pp. 80–94, Sept 2004.



LAMPIRAN A

Empirical Binary Entropies for Given Bit-Flipping Probabilities

With simulation setup given in Figure A.1, the empirical binary entropies for given bit-flipping probabilities are shown in Figure 2 [4].



Gambar A.1. System setup for obtaining p_{ABC} .